

LA CIENCIA DETRÁS DEL PODIO

MAQUINAS QUE APRENDEN DE MÁQUINAS



Minería de datos usando sistemas inteligentes

Trabajo práctico integrador

Integrantes:

-  Salvador Karakachoff, Ing. en Sistemas, Legajo: 03277/8
-  Martín Guerrino, Ing. en Sistemas, Legajo: 03747/9
-  Tomás Prieto de Francia, Ing. en Sistemas, Legajo: 03329/3

Tabla de contenido

1. Introducción.....	1
2. El mundo de la Fórmula 1: características generales	1
3. Conjunto de datos: F1 1950-2025	2
3.1. Atributos	2
Atributos faltantes	3
Valores anómalos	4
4. Análisis exploratorio	5
Distribución geográfica	5
Correlación lineal entre variables	6
Dominancia histórica	7
Efectos del clima.....	8
Agrupamiento de pilotos y escuderías, búsqueda de arquetipos	9
5. Modelos predictivos - DNF	10
5.1. Naive Bayes	10
5.2. Árboles de decisión, Random Forest y XGBoost	11
Árbol de decisión.....	11
Random Forest	13
XGBoost.....	14
Versiones regresivas de estos modelos – Variables continuas.....	15
5.3. Redes neuronales - DNF	16
5.4. Comparación entre modelos	17
6. Conclusiones	18
7. Fuentes y Referencias.....	18

1. Introducción

La Fórmula 1 (F1) es una de las competencias automovilísticas más prestigiosas y tecnológicamente avanzadas del mundo. A lo largo de sus más de 70 años de historia, ha generado una gran cantidad de datos sobre sus autos, pilotos, equipos, circuitos, condiciones climáticas y resultados. La evolución de la categoría no solo fue mecánica y reglamentaria, sino que también digital: el análisis de datos desempeña un rol importante tanto en la estrategia de carrera como en el desarrollo de vehículos y la evaluación del rendimiento de los pilotos.

Con esto en mente trabajaremos sobre un dataset histórico de Fórmula 1 que abarca desde 1950, año de su creación, hasta 2025.

Vamos a:

-  Realizar un análisis exploratorio que permita entender la evolución de la categoría a lo largo del tiempo, las características de los pilotos y escuderías, y los factores que pueden influir en el rendimiento en la competición.
-  Desarrollar modelos predictivos utilizando técnicas de clasificación y regresión, con el fin de anticipar distintos aspectos del resultado de una carrera, como la posibilidad de abandono (DNF), la posición final o la cantidad de puntos obtenidos.

2. El mundo de la Fórmula 1: características generales

La Fórmula 1 es la máxima categoría del automovilismo internacional. Desde sus inicios, reúne a las escuderías y pilotos más prestigiosos del mundo, compitiendo en una serie de Grandes Premios distribuidos globalmente.

Cada temporada, los pilotos y escuderías acumulan puntos según su rendimiento en carrera. Actualmente, el sistema de puntuación otorga puntos a los diez primeros clasificados, con 25 para el primer lugar, más un punto adicional por vuelta rápida si el piloto termina entre los diez primeros.

Factores como la posición de largada, las condiciones del circuito, el tipo de compuesto de neumáticos, el historial del piloto y el estado del clima pueden incidir de forma significativa en el resultado final y la ocurrencia de abandonos, conocidos como DNF (Did Not Finish). Por este motivo, comprender las dinámicas que llevan al éxito o al abandono se vuelve central al estudiar la Fórmula 1 desde una perspectiva basada en datos.

La riqueza de variables disponibles y la larga historia de la categoría hacen de la F1 un dominio ideal para aplicar técnicas de minería de datos, tanto en análisis exploratorios como en la construcción de modelos predictivos.

3. Conjunto de datos: F1 1950-2025

El conjunto contiene todos los datos obtenidos desde el inicio de la Formula 1 en 1950 hasta la temporada 2025, está compuesto por 25121 filas que contienen información de 92 atributos. Describen equipos, pilotos, tiempos de vuelta, clima, entre otros factores.

Los datos fueron recolectados principalmente por "Chris Newell", quien los hizo accesibles a través de la API de "Ergast Formula One". También utilizamos la API de "Meteostat" para obtener información sobre las condiciones climáticas durante las carreras.

Podemos ver una categorización y descripción más detallada de los datos a continuación.

3.1. Atributos

A continuación, una clasificación de los atributos:

Grupo de atributos	Ejemplos
Información general de la carrera	raceId, year, round, date, time...
Información del circuito	circuitId, circuitRef, location, country...
Información del piloto	driverId, forename, surname, code...
Información del equipo (constructor)	constructorId, name, nationality
Resultados y largada de carrera	grid, position, points...
Rendimiento en vuelta	fastestLap, rank, fastestLapTime, fastestLapSpeed...
Variables derivadas por carrera	avg_gap_to_team, avg_gap_to_leader, avg_points, total_points, avg_real_points...
Series temporales (últimas n carreras)	last_n_avg_position, last_n_total_points, last_n_wins, last_n_dnfs, last_n_avg_gap_to_team...
Condiciones climáticas	temperature_C, precipitation_mm, wind_speed_kmh, humidity_pct, isRainy

Los atributos nombrados con palabras en minúsculas separadas por guiones fueron obtenidos utilizando Meteostat o contruidos a partir de los datos provistos por Chris Newell (ej. avg_gap_to_team, tempretarute_C, etc.). Son variables que consideramos relevantes para enriquecer nuestro análisis, pero no estaban originalmente en el conjunto de datos.

Atributos faltantes

Al observar los atributos del conjunto de datos, nos podemos percatar de que algunos de ellos contienen valores faltantes, como se ve en la Figura 3.1.




Figura 0.1 Atributos con valores faltantes.

Para entender mejor como tratar esta falta de información estudiamos los periodos de tiempo en los que hay mayor proporción de datos ausentes Figura 3.2.




Figura 0.2 Valores faltantes por década.

Tras un breve análisis, podemos clasificar estos atributos en 4 grupos:

- 🏎️ Variables climáticas, disponibles a partir de los años 2000, previo a eso la API de Meteostat no devuelve datos.
- 🏎️ Variables relacionadas con los tiempos de vuelta, cuya precisión y disponibilidad mejoraron considerablemente desde la década de 1980 con la incorporación de cronometrajes electrónicos más exactos.
- 🏎️ Variables de rendimiento previo de los pilotos, que presentan valores ausentes en casos de debutantes o pilotos sin historial suficiente.
- 🏎️ Códigos específicos de error del monoplaza, información que comenzó a registrarse con mayor rigurosidad en las últimas décadas gracias al avance de la telemetría y los sistemas de diagnóstico automatizados.


A pesar de la existencia de datos faltantes —lo cual puede parecer una desventaja— contamos con información más que suficiente para el análisis del dataset y su posterior modelado. Además, el hecho de poder identificar claramente las causas detrás de estas ausencias nos permite tratarlas de manera informada.

En otras palabras, sabemos que responden a la evolución histórica de la

Fórmula 1, a diferencias en la tecnología de medición, y a la naturaleza condicional de ciertos atributos (por ejemplo, un piloto novato no puede tener estadísticas previas).

Valores anómalos

Utilizando el método de detección por rango Inter cuartil (IQR), podemos identificar los valores anómalos. El resultado se muestra en la Figura 3.3, donde se grafican las variables numéricas que presentan al menos un valor anómalo, ordenadas por su porcentaje de casos extremos.



Los valores detectados como anómalos en realidad no lo son en un sentido pragmático dado el contexto. Si bien se alejan de la mayoría, reflejan casos reales, esperables y lógicos dentro del dominio de la Fórmula 1:

- 🏎 Variables geográficas (lat, lng): reflejan la dispersión natural de circuitos en todo el mundo; no son errores sino variabilidad legítima.
- 🏎 Rendimiento del piloto (points, total_points, races): valores altos corresponden a pilotos destacados; representan la distribución real del desempeño.

4. Análisis exploratorio

A continuación, realizamos un análisis de los datos con la finalidad de comprender mejor su naturaleza. Comenzando con visualizaciones de las características principales del conjunto de datos y finalizando con la agrupación de pilotos y escuderías para conocer mejor sus arquetipos.

Distribución geográfica Comenzamos observando cómo se distribuye el talento alrededor del mundo en la Figura 4.1 y la Figura 4.2.




Figura 4.1 Mapas de calor que muestran la cantidad de pilotos y puntos por país.




Figura 4.2 Gráficos de barras que muestran la cantidad de pilotos y puntos por país

En los gráficos podemos ver que los países líderes en cantidad de pilotos también lideran en cantidad de puntos, como es esperable. Estos son: Reino Unido, Alemania y Francia. Con Reino Unido representando aproximadamente un 25% del total y Alemania y Francia un 15% cada uno.

En normas generales, podemos ver una fuerte dominación europea en la competición, con menciones especiales a países como Brasil, Argentina y Estados Unidos.

Esta diferencia de representación puede deberse a una combinación de factores históricos, tecnológicos y económicos. Como es sabido, Europa fue el epicentro del desarrollo automotriz y de la Fórmula 1. Adicionalmente, la mayoría de los equipos y fabricantes de Fórmula 1 tienen sede en Europa, ya que les otorga ventaja en términos de movilidad, innovación y acceso a recursos.

Correlación lineal entre variables Para identificar como se relacionan las variables entre si podemos observar la Figura 4.3.




Figura 4.3 Gráfico que muestra las correlaciones lineales más fuertes entre los pares de variables.

Más allá de las correlaciones esperables (como puntos con victorias y posición), el análisis revela algunas asociaciones menos evidentes que ofrecen una perspectiva interesante sobre el comportamiento de los pilotos y el desarrollo de las carreras a lo largo del campeonato.

gap_to_leader vs gap_to_team: sugiere que los autos que quedan más lejos del líder en una carrera suelen quedar por detrás de sus propios compañeros de equipo. Esto puede interpretarse como una señal de rendimiento individual, lo que es particularmente relevante en contextos donde uno de los pilotos del equipo es claramente superior al otro, cosa que no es ideal.

Abandonos (DNF): hay una relación significativa con variables como `race_year`, lo cual podría estar indicando una evolución técnica a lo largo del tiempo: en años más recientes, las tasas de abandono tienden a disminuir debido a mejoras en seguridad y regulaciones más estrictas. Esta hipótesis se refuerza con la correlación entre `dnf_rate` y `position_change`, que sugiere que cuando hay menos abandonos, los cambios de posición durante la carrera son menores, posiblemente por carreras más estables y predecibles.

Dominancia histórica No es misterio que a lo largo de la historia de la competición existieron pilotos y equipos excepcionales, como podemos ver en la Figura 4.4 y en la Figura 4.5.




Figura 4.4 Gráfico que muestra las escuderías con más puntos obtenidos a lo largo de la historia.




Figura 4.5 Gráfico que muestra los pilotos con más victorias con relación a su cantidad de carreras disputadas (win-rate).

Casualmente –o no tan casualmente–, los pilotos más dominantes compitieron en las escuderías más exitosas de la competencia. Ya sea porque estos equipos tienen más capital para invertir en grandes talentos, porque los pilotos talentosos hacen grandes a sus equipos, o una combinación de ambas.

Efectos del clima Nos resultó complicado establecer relaciones entre el clima y resultados como el abandono de carrera (DNF), suponemos –con fundamentos en la información brindada durante y tras las carreras a través de los medios de comunicación oficiales de la Formula 1–, que esto se debe a las medidas de seguridad especiales que toman los equipos y la organización frente a las anomalías climáticas que se presentan.

Como curiosidad, podemos ver la Figura 4.6 y la Figura 4.7 que muestran cómo se relaciona la lluvia con la no finalización de una carrera.




Figura 4.6 Gráfico muestra la cantidad de Abandonos (DNF) con y sin lluvia.




Figura 4.7 Gráfico muestra la cantidad de Abandonos (DNF) con y sin lluvia a lo largo de las décadas.

Si bien no es concluyente, el cambio casi nulo –con tendencia a una ligera disminución– en la tasa de DNF podría sugerir que los equipos tienen especial

cuidado los días con condiciones climáticas adversas, cosa que se condice con lo informado por la propia Fórmula 1.


Agrupamiento de pilotos y escuderías, búsqueda de arquetipos

Con el propósito de identificar patrones de rendimiento entre pilotos y escuderías de Fórmula 1, se aplicó el algoritmo de agrupamiento K-Medias sobre variables numéricas que describen aspectos del desempeño en carrera.

Selección de variables:

- 🏎️ avg_points, win_rate: indicadores de éxito.
- 🏎️ avg_position, avg_grid, avg_position_change: desempeño en clasificación y carrera.
- 🏎️ dnf_rate, avg_gap_to_leader: métricas asociadas a abandonos y distancia con el líder.

Dado que estas variables no están en la misma escala, se normalizaron utilizando la técnica de escalado (z-score). Luego se separaron los datos en 3 grupos, con el fin de identificar aquellas características que separan a los pilotos del promedio, como podemos ver en la Figura 4.8.



Los resultados revelan estructuras diferentes en los agrupamientos de pilotos y escuderías. En ambos casos aparece un grupo claramente destacado (Grupo 1 en pilotos y Grupo 2 en escuderías), caracterizado por altos puntajes y tasas de victoria, así como bajos valores de DNF y distancia al líder.

Sin embargo, mientras que entre los pilotos los otros dos grupos muestran diferencias más sutiles, en las escuderías se detecta un grupo notablemente inferior al resto. Esto se podría explicar por la mayor consistencia estructural de las escuderías, donde el rendimiento está más condicionado por factores como el presupuesto y la ingeniería. Por otro lado, el desempeño de los pilotos está influido tanto por su talento individual como por el equipo que los respalda y el vehículo que conducen. Además del hecho de que todos los pilotos que llegan a la Fórmula 1

forman parte de una élite global con habilidades excepcionales, contribuye a reducir las diferencias entre ellos en comparación con las escuderías.

5. Modelos predictivos - DNF

En esta sección, se abordan los modelos predictivos desarrollados con el objetivo de predecir si un piloto finalizará o no una carrera. La variable objetivo para la predicción es "DNF" (Did Not Finish), que indica si un piloto no completó la carrera. La elección de esta variable se debe a su relevancia en la Fórmula 1, ya que no terminar una carrera tiene un impacto significativo tanto en el rendimiento individual del piloto, del equipo y de cómo se deberán abordar las siguientes carreras.

Desequilibrio de clases y solución

Dada la naturaleza desequilibrada del conjunto de datos, donde la ocurrencia de DNF es probablemente menos frecuente que la de finalizar una carrera, se empleó la técnica SMOTE (Synthetic Minority Over-sampling Technique). SMOTE es un método de sobre muestreo que crea nuevas instancias de la clase minoritaria sintéticamente (en este caso, DNF), ayudando a los modelos a aprender de manera más efectiva de ambas clases y a evitar un sesgo hacia la clase mayoritaria. Esto es crucial para mejorar la capacidad predictiva de los modelos en la detección de eventos de este tipo.


Métricas de rendimiento de los modelos

La evaluación del rendimiento de todos los modelos se realizó utilizando la curva ROC (Receiver Operating Characteristic) y el área bajo la curva (AUC-ROC). El AUC-ROC es una métrica adecuada para problemas de clasificación binaria con clases desequilibradas, ya que mide la capacidad del modelo para distinguir entre clases, independientemente del umbral de clasificación. Un modelo puramente aleatorio tendría un AUC-ROC de 0.5, sirviendo este valor como línea base para comparar el rendimiento de nuestros predictores. Además, se utilizó la matriz de confusión para visualizar los tipos de errores (falsos positivos y falsos negativos) y el F1-Score para evaluar el equilibrio entre precisión y exhaustividad.

5.1. Naive Bayes

El modelo Naive Bayes fue el primer clasificador implementado. Aunque es un modelo probabilístico simple basado en el teorema de Bayes con una suposición de independencia fuerte entre las características, se incluyó como un punto de partida para establecer una línea base de rendimiento antes de pasar a modelos más complejos. Los resultados obtenidos con este modelo mostraron una mejora marginal con respecto a la línea base aleatoria (AUC-ROC de 0.5), indicando la

necesidad de algoritmos más sofisticados para capturar las complejidades de los datos, podemos ver todas las métricas en la Figura 5.1 y la Tabla 5.1.



Clase	Precision	Recall	F1-Score	Support
0	0.60	0.48	0.53	1302
1	0.57	0.69	0.62	1302
Accuracy			0.58	2604
Macro avg	0.59	0.58	0.58	2604
Weighted avg	0.59	0.58	0.58	2604

Tabla 5.1 métricas del modelo Naive Bayes.

5.2. Árboles de decisión, Random Forest y XGBoost


Tanto el árbol de decisión, como Random Forest y XGBoost, son modelos basados en estructuras jerárquicas (arbóreas, particularmente). Aunque todos utilizan árboles de decisión como bloque principal, se diferencian en cómo los entrenan y combinan: los árboles de decisión son modelos individuales, mientras que Random Forest y XGBoost son métodos de ensamblado que mejoran el rendimiento combinando múltiples árboles de distintas maneras.

Árbol de decisión

Para optimizar el modelo de Árbol de Decisión en la predicción de DNF, se implementó un proceso sistemático.

Se realizó una búsqueda en cuadrícula para explorar configuraciones del árbol (como su profundidad), buscando el equilibrio óptimo. Para asegurar la fiabilidad de la evaluación, se utilizó validación cruzada. Dada la rareza de los eventos DNF,

los pesos de las clases fueron equilibrados y el F1-Score se empleó como métrica principal. En la Figura 5.2 y la Tabla 5.2 se presentan las características del modelo y su desempeño.




Clase	Precision	Recall	F1-Score	Support
0	0.82	0.79	0.81	1302
1	0.80	0.83	0.81	1302
Accuracy			0.81	2604
Macro avg	0.81	0.81	0.81	2604
Weighted avg	0.81	0.81	0.81	2604

Tabla 5.2 métricas del modelo Árbol de decisión.

Random Forest

Para optimizar el modelo Random Forest en la predicción de DNF, se configuró y entrenó este algoritmo que construye –en este caso– 200 árboles de decisión para formar un conjunto robusto, se eligió este número haciendo un balance entre el F1-Score y el coste de cómputo. Para manejar el desequilibrio en los datos de DNF, se aplicó un ajuste de pesos de clase balanceados, asegurando que el modelo prestara la atención adecuada a la clase minoritaria. Se fijó un estado aleatorio para garantizar la reproducibilidad de los resultados. Finalmente, el modelo fue entrenado con los datos para aprender los patrones de clasificación. Este enfoque busca una alta capacidad de generalización y un rendimiento sólido en la detección de DNF. Todo esto se puede apreciar en la Figura 5.3 y en la Tabla 5.3.



Class	Precision	Recall	F1-Score	Support
0	0.88	0.93	0.91	1302
1	0.92	0.88	0.90	1302
Accuracy			0.90	2604
Macro avg	0.90	0.90	0.90	2604
Weighted avg	0.90	0.90	0.90	2604

Tabla 5.3 métricas del modelo Random Forest.

XGBoost

Se entreno también un modelo XGBoost el cual mostro un rendimiento comparable al Random Forest. Es muy curioso observar que la diferencia de pesos en las características de ambos modelos es significativa y sin embargo obtienen casi el mismo rendimiento, como podemos ver en la Figura 5.4 y en la Tabla 5.4.




Figura 5.4 Curva ROC, Matriz de confusión e importancia de variables de XGBoost.

Clase	Precision	Recall	F1-Score	Support
0	0.86	0.94	0.90	1302
1	0.93	0.85	0.89	1302
Accuracy			0.89	2604
Macro avg	0.90	0.89	0.89	2604
Weighted avg	0.90	0.89	0.89	2604

Tabla 5.4 métricas del modelo XGBoost

Versiones regresivas de estos modelos – Variables continuas.

Para tener un paneo rápido sobre modelos de regresión elegimos dos variables ordinales: posición de largada y posición de llegada. Intentamos predecirlas. Los modelos que elegimos fueron las versiones de regresión de los vistos anteriormente. Si bien los resultados no fueron completamente desastrosos, se alejan de ser idóneos, le atribuimos esto al posible ruido en variables como las posiciones, que varían mucho dependiendo del clima, políticas internas, estados de ánimo de los pilotos, entre otras. Para obtener mejores resultados se podrían discretizar las posiciones en intervalos, por ejemplo 1-5, 5-10 y 10-20, pero lo vamos a omitir por no ser el objetivo de este estudio, que es principalmente predecir los DNFs.

En la Tabla 5.5 podemos observar los resultados obtenidos y comparar los modelos entre sí.

Modelo	MAE (Error Absoluto Medio)	MSE (Error Cuadrático Medio)	R ² (Coef. de Determinación)
ZeroR	5.999	47.91	≈ 0
Decision Tree	3.35	26.08	0.46
Random Forest	2.67	13.19	0.72
XGBoost	2.85	14.93	0.69

Tabla 5.5 Métricas de los modelos regresivos utilizados


Se utilizaron tres métricas estándar para evaluar el desempeño:

- MAE (Mean Absolute Error): mide el error promedio absoluto entre las predicciones y los valores reales. Valores menores indican mayor precisión.
- MSE (Mean Squared Error): penaliza errores grandes con mayor fuerza, lo que lo hace útil para detectar outliers.
- R² (Coeficiente de determinación): representa la proporción de la varianza explicada por el modelo. Un valor de 1 indica predicción perfecta, mientras que valores cercanos a 0 o negativos indican bajo poder explicativo.

El modelo ZeroR, que predice siempre el mismo valor (como la media o moda), funciona como línea base, y muestra un MAE cercano a 6 y un R² prácticamente nulo, lo que evidencia su baja utilidad. En contraste, el Árbol de Decisión logra una mejora notable, con un R² de 0.46. Sin embargo, el mejor desempeño lo alcanza Random Forest, que reduce el MAE a 2.67 y alcanza un R² de 0.72, lo que indica que capta buena parte de la variabilidad del problema. XGBoost obtiene resultados

similares, aunque levemente inferiores, posiblemente por una mayor sensibilidad al ruido en los datos, podría aprovecharse mejor el boosteo con un dataset mayor.

En conclusión, los modelos de ensamblado, especialmente Random Forest, resultan los más efectivos para esta tarea en concreto. Podemos observar la Figura 5.5 tener una noción visual de las predicciones.



5.3. Redes neuronales - DNF

En este caso se construyó una red para la predicción de DNF que se compone de múltiples capas densas (Dense), que varían en el número de neuronas (desde 128 hasta 32 en las capas ocultas), con la función de activación ReLU para introducir no linealidad. Para mejorar la estabilidad del entrenamiento y acelerar la convergencia, se integró Batch Normalization después de varias capas densas. Con el fin de mitigar el sobreajuste y fomentar una mejor generalización, se implementó Dropout en varias capas ocultas, y también se aplicó regularización L2 a los pesos del kernel de algunas capas densas. La capa de salida consta de una única neurona con activación Sigmoide, lo que es apropiado para la clasificación binaria, ya que produce una probabilidad entre 0 y 1. El modelo fue compilado utilizando el optimizador Adam y la función de pérdida binary cross-entropy, con la precisión (accuracy) como métrica principal de evaluación. Véase la Figura 5.6 y la Tabla 5.6.




Figura 5.6 Curva ROC y Matriz de confusión de la Red Neuronal.

Clase	Precision	Recall	F1-Score	Support
0	0.86	0.82	0.84	1302
1	0.83	0.86	0.84	1302
Accuracy			0.84	2604
Macro avg	0.84	0.84	0.84	2604
Weighted avg	0.84	0.84	0.84	2604

Tabla 5.6 Métricas del modelo de Red Neuronal.

5.4. Comparación entre modelos

En la siguiente Figura 5.7 podemos comparar los resultados obtenidos por los diferentes modelos.




Figura 5.7 Gráficos comparativos de Accuracy, ROC-AUC y F1-Score entre los modelos utilizados para predecir DNF.

En la predicción de DNF se observó que los modelos avanzados, incluyendo Random Forest, XGBoost y la Red Neuronal, demostraron un excelente rendimiento predictivo, alcanzando consistentemente métricas de AUC ROC y Accuracy superiores al 90%, lo que los valida como herramientas efectivas para la predicción de abandonos. No obstante, Random Forest se destacó como el modelo de mayor desempeño. Esta superioridad sobre la red neuronal, a pesar de su complejidad, puede atribuirse a su robustez inherente y su idoneidad para datos tabulares. Su diseño de ensamble le permite generalizar muy bien, mitigando el sobreajuste de forma más eficiente que las redes neuronales en este tipo de sets de datos.

6. Conclusiones

En este informe nos enfocamos en comprender las relaciones de aquellas variables que reflejan el rendimiento de los pilotos, entre ellas y con atributos externos, como el clima. Analizamos sus implicaciones en la práctica y racionalizamos los resultados obtenidos.

Las visualizaciones y agrupamientos permitieron detectar arquetipos claros de escuderías y pilotos, diferenciando no solo por talento individual sino también por consistencia técnica.

Utilizando el conocimiento y datos obtenidos en este análisis preliminar, más los datos del conjunto original, se entrenaron modelos predictivos para predecir si un piloto logrará o no finalizar una carrera en particular.

Los equipos podrían usar estos modelos para anticipar riesgos de abandono, simular condiciones hipotéticas y evaluar el rendimiento de sus pilotos para así planificar estrategias acordes.

Para finalizar, dejamos abierta la puerta a profundizar en la predicción de posiciones, teniendo en cuenta los resultados obtenidos y habiendo identificado los puntos a mejorar en nuestros modelos actuales.

7. Fuentes y Referencias

- [1] [Kaggle](#) – Repositorio de datos de donde se obtuvo gran parte del dataset.
- [2] [Chris Newell](#) – Autor del set de datos.
- [3] APIs del dataset y datos climáticos - [Ergast](#) y [Meteostat](#).
- [4] [Formula 1](#) - Sitio web oficial de la Formula 1.